4.1 深层神经网络（Deep L-layer neural network）

目前为止我们学习了只有一个单独隐藏层的神经网络的**正向传播和反向传播**，还有逻辑回归，并且你还学到了**向量化**，这在随机初始化权重时是很重要。

本周所要做的是把这些理念集合起来，就可以执行你自己的深度神经网络。

复习下前三周的课的内容：

1.逻辑回归，结构如下图左边。一个隐藏层的神经网络，结构下图右边：

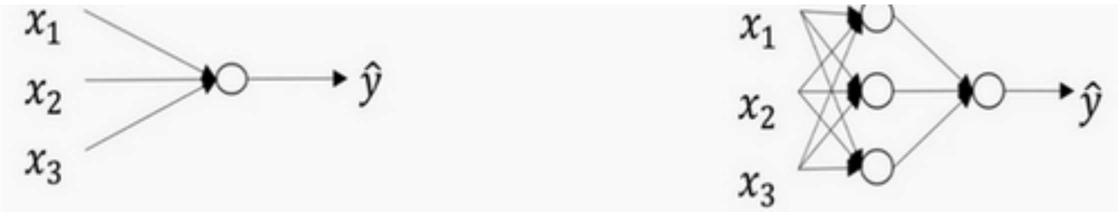

注意，神经网络的层数是这么定义的：**从左到右，由 0 开始定义**，比如上边右图，x_1、x_2、x_3,这层是第 0 层，这层左边的隐藏层是第 1 层，由此类推。如下图左边是两个隐藏层的神经网络，右边是 5 个隐藏层的神经网络。

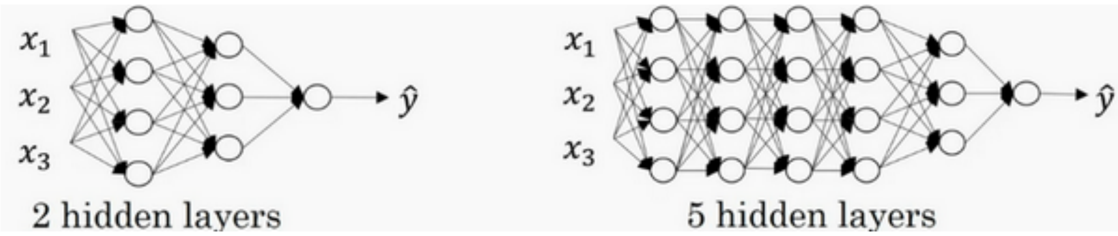

严格上来说逻辑回归也是一个一层的神经网络，而上边右图一个深得多的模型，浅与深仅仅是指一种程度。记住以下要点：

有一个隐藏层的神经网络，就是一个两层神经网络。记住当我们算神经网络的层数时，我们不算输入层，我们只算隐藏层和输出层。

但是在过去的几年中，**DLI**（深度学习学院 **deep learning institute**）已经意识到有一些函数，只有非常深的神经网络能学会，而更浅的模型则办不到。尽管对于任何给定的问题很难去提前预测到底需要多深的神经网络，所以先去尝试逻辑回归，尝试一层然后两层隐含层，然后把隐含层的数量看做是另一个可以自由选择大小的超参数，然后再保留交叉验证数据上评估，或者用你的开发集来评估。

我们再看下深度学习的符号定义：

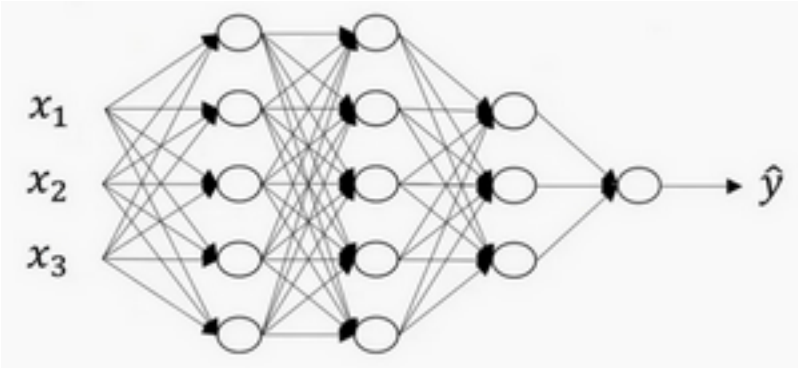

上图是一个四层的神经网络，有三个隐藏层。我们可以看到，第一层（即左边数过去第二层，因为输入层是第 0 层）有 5 个神经元数目，第二层 5 个，第三层 3 个。

我们用 L 表示层数，上图：$L = 4$，输入层的索引为“0”，第一个隐藏层$n^{[1]} = 5$,表示有 5 个隐藏神经元，同理$n^{[2]} = 5$，$n^{[3]} = 3$，$n^{[4]}$=$n^{[L]} = 1$（输出单元为 1）。而输入层，$n^{[0]} = n_x = 3$。

在不同层所拥有的神经元的数目，对于每层 *l* 都用$a^{[l]}$来记作 *l* 层激活后结果，我们会在后面看到在正向传播时，最终能你会计算出$a^{[l]}$。

通过用激活函数 g 计算$z^{[l]}$，激活函数也被索引为层数l，然后我们用$w^{[l]}$来记作在 *l* 层计算$z^{[l]}$值的权重。类似的，$z^{[l]}$里的方程$b^{[l]}$也一样。

最后总结下符号约定：

输入的特征记作x，但是x同样也是 0 层的激活函数，所以$x = a^{[0]}$。

最后一层的激活函数，所以$a^{[L]}$是等于这个神经网络所预测的输出结果。

但是如果你忘记了某些符号的意义，请看笔记最后的附件：《深度学习符号指南》。

4.2 前向传播和反向传播（Forward and backward propagation）

之前我们学习了构成深度神经网络的基本模块，比如每一层都有前向传播步骤以及一个相反的反向传播步骤，这次视频我们讲讲如何实现这些步骤。

先讲前向传播，输入$a^{[l-1]}$，输出是$a^{[l]}$，缓存为$z^{[l]}$；从实现的角度来说我们可以缓存下$w^{[l]}$和$b^{[l]}$，这样更容易在不同的环节中调用函数。

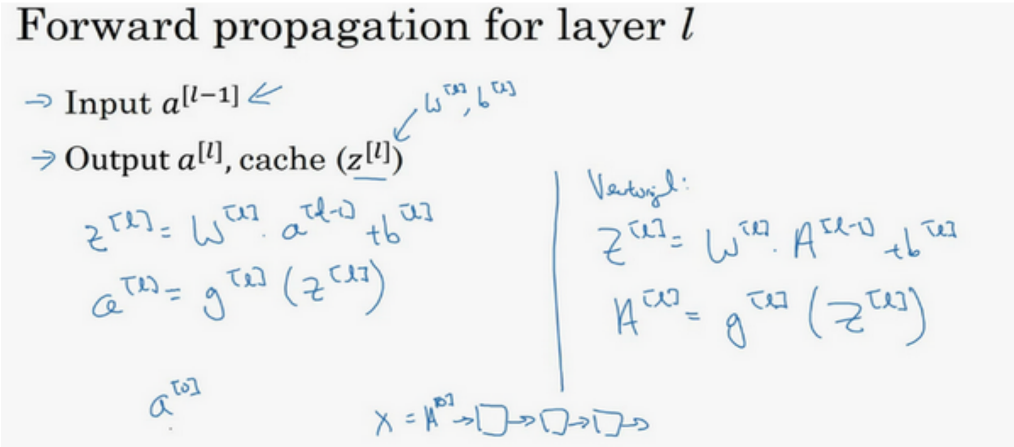

所以前向传播的步骤可以写成： $z^{[l]} = W^{[l]} \cdot a^{[l-1]} + b^{[l]}$

$a^{[l]} = g^{[l]}\left(z^{[l]}\right)$

向量化实现过程可以写成： $z^{[l]} = W^{[l]} \cdot A^{[l-1]} + b^{[l]}$

$A^{[l]} = g^{[l]}(Z^{[l]})$

前向传播需要喂入$A^{[0]}$也就是X，来初始化；初始化的是第一层的输入值。$a^{[0]}$对应于一个训练样本的输入特征，而$A^{[0]}$对应于一整个训练样本的输入特征，所以这就是这条链的第一个前向函数的输入，重复这个步骤就可以从左到右计算前向传播。

下面讲反向传播的步骤：

输入为$da^{[l]}$，输出为$da^{[l-1]}$，$dw^{[l]}$，$db^{[l]}$

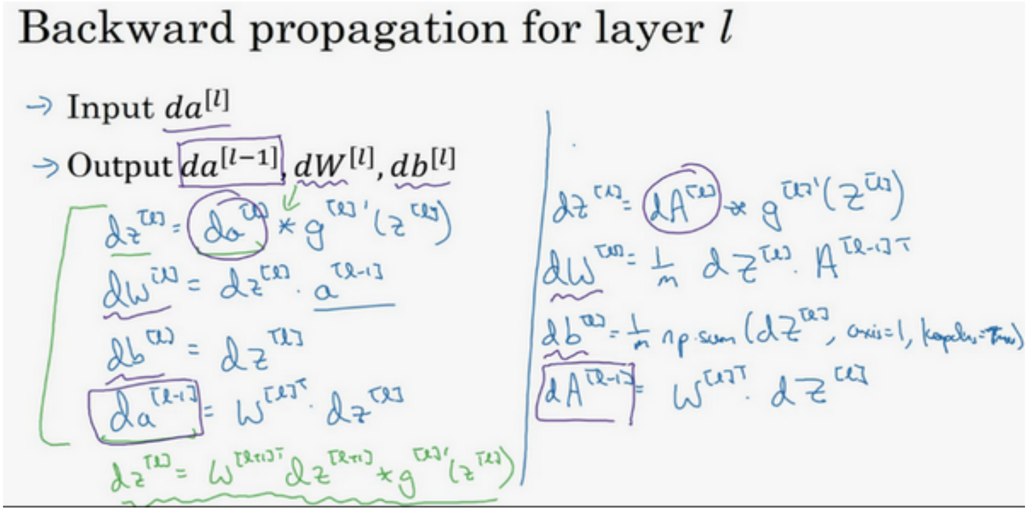

所以反向传播的步骤可以写成：

（1）$dz^{[l]} = da^{[l]} * g^{[l]}{'}(z^{[l]})$

（2）$dw^{[l]} = dz^{[l]} \cdot a^{[l-1]}$

（3）$db^{[l]} = dz^{[l]}$

（4）$da^{[l-1]} = w^{[l]T} \cdot dz^{[l]}$

（5）$dz^{[l]} = w^{[l+1]T} dz^{[l+1]} \cdot \ g^{[l]}{'}(z^{[l]})$

式子（5）由式子（4）带入式子（1）得到，前四个式子就可实现反向函数。

向量化实现过程可以写成：

（6）$dZ^{[l]} = dA^{[l]} * g^{[l]}{'}\left(Z^{[l]}\right)$

（7）$dW^{[l]} = \frac{1}{m} dZ^{[l]} \cdot A^{[l-1]T}$

（8）$db^{[l]} = \frac{1}{m}\ np.sum(dz^{[l]}, axis = 1, keepdims = True)$

（9）$dA^{[l-1]} = W^{[l]T}.dZ^{[l]}$

总结一下：

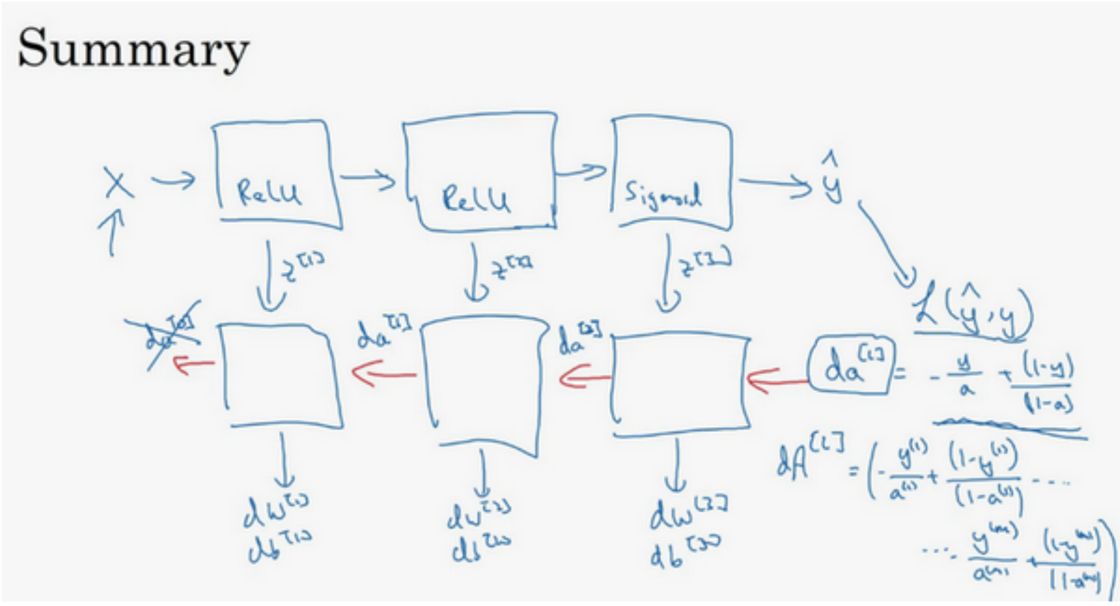

第一层你可能有一个 **ReLU** 激活函数，第二层为另一个 **ReLU** 激活函数，第三层可能是 **sigmoid** 函数（如果你做二分类的话），输出值为，用来计算损失；这样你就可以向后迭代进行反向传播求导来求$dw^{[3]}$，$db^{[3]}$ ，$dw^{[2]}$ ，$db^{[2]}$ ，$dw^{[1]}$ ，$db^{[1]}$。在计算的时候，缓存会把$z^{[1]}$ $z^{[2]}z^{[3]}$传递过来，然后回传$da^{[2]}$，$da^{[1]}$ ，可以用来计算$da^{[0]}$，但我们不会使用它，这里讲述了一个三层网络的前向和反向传播，还有一个细节没讲就是前向递归——用输入数据来初始化，那么反向递归（使用 **Logistic** 回归做二分类）——对$A^{[l]}$ 求导。

忠告：补补微积分和线性代数，多推导，多实践。